



UNIVERSIDAD
CATÓLICA
BOLIVIANA
ERIGIDA CANÓNICAMENTE
POR LA SANTA SEDE DESDE 2023

Universidad Católica Boliviana “San Pablo”

Maestría en Ciencia de Datos e Inteligencia Artificial Aplicada

Módulo: Visión Computacional

Detección y clasificación de defectos en superficies metálicas con aprendizaje profundo: del entrenamiento en GPU a una demo web en tiempo real

Equipo de Proyecto

Simon Alex Rodriguez Saavedra	<i>Líder / Integrador</i>
Jennifer Suarez Gutierrez	<i>Entrenamiento CNN baseline</i>
Daniel Ribera Añez	<i>Contribuidor</i>
Daniela Alejandra Caro Arrazola	<i>Contribuidora</i>

Agosto-2026

Repositorio del proyecto (código fuente, datos, modelos y demo web):
<https://github.com/SimonLexRS/vision-computacional>

Resumen

Este proyecto presenta el desarrollo, evaluación y despliegue de un sistema de inspección automatizada para la detección y clasificación de defectos superficiales en piezas metálicas, optimizado para entornos de acero laminado. Frente a la variabilidad, subjetividad y fatiga asociadas al control de calidad manual, se propone una arquitectura jerárquica de dos etapas orientada al balance óptimo entre eficiencia computacional y precisión analítica: (1) un clasificador de dominio (*Gate*) basado en MobileNetV3-Small (1.5M parámetros) que actúa como filtro binario de alta velocidad para discriminar si la escena es una superficie metálica válida o descartar entradas fuera de dominio (OOD), seguido de (2) un detector YOLOv8n (3.2M parámetros) para la localización multiclase y acotación mediante cajas delimitadoras de las fallas detectadas.

El entrenamiento se realizó sobre un dataset híbrido de 17 250 imágenes combinando muestras sintéticas con benchmarks reales de la industria (*SteelDefectX* y *NEU-DET*). Los resultados cuantitativos evidencian un desempeño sobresaliente, alcanzando un F1-Macro de 1.0000 en la clasificación de dominio y un mAP_{50} de 0.739 ($mAP_{50-95} = 0.488$) en el detector sobre un conjunto de prueba que integra imágenes reales con anotaciones manuales expertas. Finalmente, el sistema fue exportado a formato ONNX y desplegado en cliente mediante ONNX Runtime Web con aceleración WebAssembly multi-hilo, alcanzando tasas de inferencia en tiempo real de 20–30+ FPS en el navegador sin dependencia de servidores externos, demostrando la viabilidad de modelos ligeros para la toma de decisiones críticas en líneas de producción industrial.

Palabras clave: Visión computacional, detección de defectos, superficies metálicas, acero laminado, MobileNetV3, YOLOv8, ONNX Runtime Web, tiempo real.

1. Introducción y motivación

1.1. Definición del problema

La identificación oportuna de irregularidades superficiales es una tarea crítica en la industria metalúrgica y siderúrgica. Pequeñas discontinuidades en el material pueden comprometer la resistencia mecánica, la durabilidad contra la corrosión y la conformidad técnica de las piezas antes de su comercialización. El objetivo principal de este trabajo es localizar y clasificar de forma autónoma cuatro tipos de defectos recurrentes:

- **Grietas (*cracks*):** Fisuras longitudinales o transversales que comprometen la integridad estructural del material.
- **Perforaciones (*holes*):** Cavidades, porosidades o inclusiones profundas en la lámina.
- **Óxido (*rust*):** Áreas afectadas por corrosión, escamas de óxido o degradación superficial.
- **Rayones (*scratches*):** Daños mecánicos por abrasión, fricción o marcas de rodillos de laminación.

La meta es transformar la inspección visual subjetiva en un proceso analítico estandarizado, cuantitativo y gobernado por datos.

1.2. Caso de uso e industria

El caso de aplicación se sitúa en líneas de producción continua de acero laminado en caliente y en frío. En este entorno, tiras y placas metálicas se desplazan a altas velocidades bajo condiciones de iluminación variables y atmósferas con polvo o temperatura. Al procesar flujos de video en vivo provenientes de cámaras cenitales situadas sobre las líneas transportadoras, la solución posibilita una supervisión constante y exhaustiva de la calidad del material previa a su bobinado, corte y distribución final.

1.3. Justificación

La inspección manual tradicional presenta limitaciones inherentes: es lenta, propensa al error humano derivado de la fatiga visual prolongada y carece de uniformidad en los criterios de rechazo entre diferentes turnos de trabajo. La implementación de un pipeline automatizado de baja latencia permite alcanzar una inspección del 100 % de la producción (en contraste con el muestreo estadístico tradicional). Esto viabiliza el rechazo o reencauzamiento inmediato de lotes anómalos, minimizando los costos de reprocesamiento, desperdicio de material y reclamaciones post-venta por garantías.

1.4. Aporte del proyecto

Este trabajo entrega un pipeline técnico completo, reproducible y de código abierto:

1. **Ingeniería y unificación de datos:** Integración y armonización taxonómica de tres fuentes de datos (sintéticas y reales) totalizando 17 250 muestras balanceadas y estratificadas.
2. **Arquitectura jerárquica de dos etapas:** Desacoplamiento de la validación de dominio (*Gate OOD*) y la detección de objetos multiclase (YOLOv8n), maximizando la eficiencia computacional y evitando falsos positivos sobre fondos no pertinentes.
3. **Entrenamiento y benchmarking riguroso:** Transfer learning y comparativa frente a una CNN baseline entrenada desde cero, evaluando con métricas estándar de la industria (mAP₅₀, mAP₅₀₋₉₅, F1-Macro).

4. **Despliegue web en tiempo real:** Exportación a formato interoperable ONNX (opset 17), verificación estricta de paridad numérica contra PyTorch y ejecución client-side mediante ONNX Runtime Web con WebAssembly multi-hilo a 20–30+ FPS con cámara en vivo y filtros anti-ruido calibrados.

2. Datos

2.1. Composición y procedencia

El robustecimiento de los modelos ante la variabilidad geométrica y de texturas se logró mediante la fusión estratégica de tres fuentes complementarias de datos (Tabla 1), alcanzando un volumen final de 17 250 muestras tras un riguroso proceso de estandarización:

1. **Synthetic Industrial Metal Surface Defects (Abbas, Kaggle) [3]:** 15 000 imágenes sintéticas equilibradas (3 000 por clase) que abarcan texturas metálicas homogéneas y las 5 clases del proyecto (**crack**, **hole**, **normal**, **rust**, **scratch**). Dispone de metadata posicional y licencia CC BY 4.0.
2. **SteelDefectX (Zhao et al., 2024) [2]:** Subconjunto representativo de 480 imágenes curadas de un benchmark industrial real de 5 454 muestras en entornos de fundición y conformado.
3. **NEU Surface Defect Database (Northeastern University, Song & Yan, 2013) [1]:** Benchmark de referencia internacional con 1 770 imágenes reales de defectos en tiras de acero laminado en caliente, dotado de **anotaciones manuales de cajas delimitadoras** por expertos (formato Pascal VOC XML). De las 1 800 imágenes originales, se filtraron 1 770 pares válidos verificados.

Cuadro 1: Fuentes de datos que conforman el dataset combinado.

Fuente	Imágenes	Tipo	Anotación / Licencia
Synthetic Industrial Defects [3]	15 000	Sintética	Metadata de posición; cajas derivadas con OpenCV. CC BY 4.0.
SteelDefectX (Zhao et al., 2024) [2]	480	Real	Etiqueta de clase por imagen; cajas estimadas con OpenCV. Académica.
NEU-DET (Song & Yan, 2013) [1]	1 770	Real	Cajas reales anotadas por expertos (Pascal VOC XML). Académica.
Total consolidado	17 250	Híbrido	Taxonomía unificada de 4 clases de defecto + normal.

2.2. Mapeo de clases y taxonomía

Dado que las fuentes originales empleaban terminologías heterogéneas, se realizó una ingeniería de etiquetas para unificar los defectos en las cuatro clases estándar del detector:

- **crack (Grieta):** Integración de las clases originales *Crazing* (fisuración superficial en red), *Crease* (arrugas/pliegues de compresión) y *Waist folding* (pliegue transversal).
- **scratch (Rayón):** Integración de *Bright scratch* (rayón brillante), *Dark scratches* (rayones oscuros por arrastre) y *Finishing roll printing* (marcas periódicas de rodillo).
- **rust (Óxido):** Integración de *Oxide scale* (escama de laminación), *Pitted surface* (superficie picada), *Red iron sheet* (óxido ferroso) y *White rust* (óxido de zinc/blanco).

- **hole (Perforación):** Integración de *Punching* (agujero de troquelado), *Inclusion* (inclusiones no metálicas) y *Crescent gap* (muescas marginales en medialuna).

Para el modelo de clasificación de dominio (*Gate*), se conservó la clase **normal** (3 000 muestras sintéticas libres de fallas) para entrenar la discriminación entre superficies sanas y defectuosas.

2.3. Distribución cuantitativa y partición de datos

Para garantizar la validez metodológica y evitar el sobreajuste o fuga de datos entre conjuntos, se aplicó una partición física determinista **80/10/10** estratificada por clase y por fuente con semilla fija (SEED = 42). En la Tabla 2 se detalla la composición exacta de cada partición.

Cuadro 2: Distribución cuantitativa del dataset híbrido por partición y fuente (80/10/10 estratificada, SEED = 42).

Partición	Sintéticas (Abbas)	SteelDefectX	NEU-DET	Total Imágenes (%)
Entrenamiento (<i>Train</i>)	12 000	384	1 416	13 800 (80.0 %)
Validación (<i>Val</i>)	1 500	48	177	1 725 (10.0 %)
Prueba (<i>Test</i>)	1 500	48	177	1 725 (10.0 %)
Total por Fuente	15 000	480	1 770	17 250 (100.0 %)

2.4. Limitaciones técnicas de los datos

Se identificaron tres factores de relevancia:

1. **Disparidad en la calidad de las cajas delimitadoras:** Mientras que NEU-DET cuenta con anotaciones manuales rigurosas realizadas por expertos, las muestras sintéticas y de SteelDefectX dependen de cajas heurísticas generadas mediante segmentación morfológica tradicional con OpenCV. Esto introduce cierta imprecisión geométrica en los bordes finos de las cajas delimitadoras.
2. **Brecha sintético-a-real (*sim-to-real gap*):** La fuente sintética representa el 87 % del volumen total, lo que provee una base estadística amplia para el aprendizaje de texturas base pero exige validar el comportamiento ante ruido real de sensor.
3. **Espacio de color y representatividad:** Las imágenes industriales analizadas son predominantemente monocromáticas o en escala de grises. Escenas con fondos no industriales saturados o con tonalidades dispares son tratadas deliberadamente como *Fuera de Dominio* (OOD) por el Gate.

3. Metodología

3.1. Arquitectura jerárquica de dos etapas

Para optimizar el presupuesto computacional y garantizar una respuesta de latencia mínima en entornos industriales, se concibió un pipeline en cascada (Fig. 1):

1. **Etapla 1: Filtro y Gate de dominio.** Implementado mediante **MobileNetV3-Small** [4] (1.5M parámetros), optimizado para inferencia en bordes y navegadores. Clasifica la escena en las 5 categorías base. Si la imagen corresponde a un fondo no metálico, escena saturada o fuera de dominio (OOD), el sistema detiene inmediatamente el procesamiento, previniendo falsas alarmas y evitando el consumo de cómputo en el detector principal.

2. **Etapla 2: Detector multiclase.** Si el Gate valida la superficie metálica como perteneciente al dominio, la imagen pasa a **YOLOv8n** [5] (3.2M parámetros). El detector predice de forma simultánea la ubicación espacial (cajas *xywh*), la clase de falla (**crack**, **hole**, **rust**, **scratch**) y la probabilidad de confianza.




Figura 1: Esquema conceptual del pipeline de inferencia jerárquico de dos etapas.

3.2. Preprocesamiento y data augmentation

Las imágenes de entrada se redimensionan a una resolución uniforme de 256×256 píxeles. El canal de grises se replica a tres canales RGB para aprovechar las inicializaciones preentrenadas de ImageNet y COCO. En clasificación, se normaliza con la media y desviación estándar de ImageNet; en detección, los píxeles se reescalan al intervalo $[0, 1]$.

Durante el entrenamiento se aplicaron técnicas de aumento de datos (*data augmentation*) seleccionadas para conferir invariancia frente a condiciones adversas de iluminación y escala: perturbación tonal (HSV jitter), rotaciones (10°), traslación, escalado, volteo horizontal/vertical (*flips*), mosaico (*Mosaic* 0.5) y mezcla lineal (*Mixup* 0.1) para mejorar la detección de micro-defectos.

3.3. Configuración de entrenamiento y reproducibilidad

El entrenamiento se ejecutó de forma controlada y reproducible:

- **Hardware:** GPU NVIDIA GeForce RTX 5060 Ti con CUDA y PyTorch.
- **Optimizadores y scheduling:** Para los clasificadores se empleó AdamW con $lr = 3 \times 10^{-4}$ y weight decay 10^{-4} . Para YOLOv8n se empleó SGD con momentum 0.937, weight decay 5×10^{-4} y aprendizaje por decaimiento coseno (*cosine annealing*) con tasa inicial 0.01.
- **Precisión mixta (AMP float16):** Reducción de huella de memoria en GPU y aceleración del tiempo de cómputo sin degradar la precisión numérica.
- **Criterios de parada y consistencia:** Semilla global fijada en $SEED = 42$ y parada temprana (*Early Stopping*) monitoreando el F1-Macro en validación (clasificación) y mAP_{50} (detección). El conjunto de prueba (*Test*) se evaluó **una sola vez** al finalizar todos los ajustes sobre el mejor checkpoint guardado.

Cuadro 3: Resumen de hiperparámetros de entrenamiento.

Parámetro	Clasificadores (Gate / Baselines)	Detector YOLOv8n
Optimizador	AdamW	SGD (momentum 0.937)
Tasa de aprendizaje base	3×10^{-4}	0.01 (Cosine decay)
Weight decay	10^{-4}	5×10^{-4}
Tamaño de lote (<i>Batch size</i>)	32	64
Épocas máximas / Paciencia	20 / 5	60 / 15
Aumento de datos	Flips, rotación, color jitter	HSV, Mosaic (0.5), Mixup (0.1), Flips
Precisión mixta (AMP)	Sí (float16)	Sí (float16)
Resolución de entrada	$256 \times 256 \times 3$	$256 \times 256 \times 3$


4. Resultados

4.1. Clasificación de dominio y modelos baseline

La evaluación final sobre el split de prueba independiente (1 500 imágenes sintéticas no vistas en el entrenamiento) se expone en la Tabla 4. Los tres modelos basados en *transfer learning* alcanzaron un F1-Macro perfecto de 1.0000 tras pocas épocas de convergencia. La arquitectura CNN entrenada desde cero como baseline (desarrollada y entrenada por Jennifer Suarez Gutierrez) obtuvo una exactitud del 99.87 % y un F1-Macro de 0.9987 con solo 391K parámetros.

Cuadro 4: Métricas de desempeño en clasificación sobre el conjunto de prueba (5 clases).

Modelo	Parámetros	Épocas	Accuracy	F1-Macro	Rol en Pipeline
MobileNetV3-Small [4]	1.5M	6	1.0000	1.0000	Gate de Dominio (Desplegado)
EfficientNet-B0 [7]	4.0M	6	1.0000	1.0000	Modelo de referencia
ResNet-18 [6]	11.2M	7	1.0000	1.0000	Modelo de referencia
CNN Baseline (desde cero)	391K	17	0.9987	0.9987	Baseline comparativo

**Figura 2:** Curvas de entrenamiento de los modelos preentrenados (pérdida train/val y evolución de F1): rápida convergencia sin sobreajuste aparente.




Figura 3: Matrices de confusión en test para los modelos preentrenados: diagonal pura (300 aciertos por clase en cada modelo).




Figura 4: Muestras de inferencia cualitativa en clasificación (ResNet-18) sobre imágenes de prueba.

4.2. Detección de objetos con YOLOv8n

La evaluación del detector se ejecutó sobre el split de prueba combinado de 1 725 imágenes (que integra 1 500 sintéticas, 48 de SteelDefectX y 177 de NEU-DET con cajas reales). En la Tabla 5 y Tabla 6 se desglosan las métricas cuantitativas obtenidas.

Cuadro 5: Métricas globales de detección de YOLOv8n sobre el conjunto de prueba (1 725 imágenes).

Métrica	mAP ₅₀	mAP ₅₀₋₉₅	Precisión (<i>Precision</i>)	Exhaustividad (<i>Recall</i>)
Valor	0.739	0.488	0.754	0.663

Cuadro 6: Desempeño del detector YOLOv8n desglosado por clase de defecto.

Clase de Defecto	AP ₅₀	AP ₅₀₋₉₅	Comportamiento Físico Observado
hole (Perforación)	0.846	0.645	Geometría delimitada, contraste nítido con el fondo.
crack (Grieta)	0.791	0.541	Alta precisión en fisuras continuas; sensible a aperturas finas.
rust (Óxido)	0.677	0.407	Bordes difusos y variabilidad de tonalidad superficial.
scratch (Rayón)	0.643	0.361	Trazos extremadamente finos sensibles a la resolución de 256px.
Promedio Global (mAP)	0.739	0.488	Rendimiento balanceado para inspección industrial.




Figura 5: Curvas de aprendizaje de YOLOv8n durante 60 épocas de entrenamiento en GPU RTX 5060 Ti: pérdidas de caja y clasificación (train/val), y evolución de mAP₅₀, mAP₅₀₋₉₅, precisión y recall.




Figura 6: Predicciones cualitativas de YOLOv8n sobre muestras de prueba: localización mediante caja delimitadora, asignación de clase y score de confianza.

4.3. Análisis cualitativo y diagnóstico de errores

El análisis minucioso de las predicciones arrojó patrones sistemáticos sobre aciertos y fallos (Fig. 7):

- **Caso A (Detección Correcta – hole):** El detector localiza perforaciones circulares e inclusiones con alta precisión y puntuaciones de confianza superiores a 0.85, incluso en láminas con baja reflectancia o iluminación no uniforme.
- **Caso B (Falso Positivo – rust):** Se observaron casos en donde texturas rugosas o bandas oscuras de rodillos industriales fueron clasificadas falsamente como óxido. *Hipótesis:* La distribución de frecuencias espaciales y ruido de sensor en patrones difusos guarda una fuerte correlación visual con las texturas de óxido sintético.
- **Falsos Negativos en crack y scratch:** De los falsos negativos identificados con umbral de confianza ≥ 0.5 , la mayor proporción corresponde a fisuras y rayones muy tenues. Al reescalar las imágenes a 256×256 , estas estructuras lineales ocupan apenas 1 a 2 píxeles de grosor, lo que dificulta el solapamiento estricto de intersección sobre unión (IoU) y reduce la puntuación de confianza del modelo.
- **Errores de Clasificación Baseline (2 fallos en 1 500):** La CNN baseline confundió una grieta tenue con superficie `normal` (confianza 0.51 vs 0.38) y un parche de óxido incipiente con `normal` (confianza 0.70), ambos en imágenes con contraste casi imperceptible.




Figura 7: Diagnóstico de predicciones erróneas en el conjunto de prueba. Fila superior: 2 casos de clasificación incorrecta en la CNN baseline por bajo contraste. Filas inferiores: falsos negativos de YOLOv8n ($\text{conf} \geq 0.5$) en grietas y micro-defectos lineales a baja resolución.

4.4. Despliegue web e inferencia en tiempo real

Ambos modelos fueron convertidos al estándar abierto ONNX (opset 17), validando la paridad numérica exacta contra la ejecución en PyTorch (IoU medio de 1.0000 en cajas y concordancia en probabilidades de clase).

El sistema cliente opera en navegadores web modernos mediante **ONNX Runtime Web** y el backend de **WebAssembly (WASM) multi-hilo**, prescindiendo de servidores de cómputo y garantizando la privacidad de los datos en planta. En pruebas de estrés se alcanzaron tasas de **20–30+ FPS** en video en directo (Fig. 8).




Figura 8: Validación operativa de la aplicación web en tiempo real. Izquierda: detección en vivo de grieta con caja y confianza. Derecha: el clasificador Gate rechaza una escena no industrial categorizándola como *Fuera de Dominio* (OOD).

5. Discusión y limitaciones

Efecto de la inclusión de benchmarks reales: Al integrar el dataset NEU-DET en la evaluación, el mAP₅₀ global pasó de 0.80 (en datasets exclusivamente sintéticos o semi-heurísticos) a 0.739. Lejos de considerarse un deterioro, este resultado representa un avance metodológico positivo: NEU-DET incorpora anotaciones manuales de expertos sobre piezas reales de acería, ofreciendo una métrica mucho más honesta, rigurosa y cercana a las condiciones reales de planta.

Validez de la clasificación perfecta ($F1 = 1.0$): El resultado de $F1\text{-Macro} = 1.0000$ en los clasificadores con transfer learning debe interpretarse como una *cota superior en laboratorio*. Si bien el filtro Gate discrimina con absoluta eficacia fondos no metálicos y escenas OOD sintéticas, la brecha *sim-to-real* sugiere que en planta la presencia de suciedad extrema, aceites de corte o cambios bruscos de iluminación podría degradar ligeramente dicha métrica si no se recalibra periódicamente.

Ruido en etiquetas y regresión de cajas: El uso de cajas heurísticas basadas en segmentación por OpenCV para los datos sintéticos y SteelDefectX impone un techo a la métrica mAP₅₀₋₉₅ (0.488). Una fracción de la pérdida de localización (*localization loss*) se debe a la imperfección geométrica de las etiquetas de entrenamiento y no a una deficiencia intrínseca de la arquitectura de la red.

Comportamiento de las curvas de entrenamiento: Al completar las 60 épocas en YOLOv8n, la curva de mAP₅₀ continuaba exhibiendo una pendiente positiva leve sin saturación de *early stopping*, lo que evidencia que un entrenamiento más prolongado (100+ épocas) sobre el dataset consolidado de tres fuentes incrementaría aún más la capacidad de detección.

6. Trabajo futuro

A partir de los hallazgos del proyecto, se delinean tres líneas prioritarias de extensión técnica:

1. **Hardware de borde y cuantización INT8 (*Edge Computing*):** Optimizar el grafo computacional mediante cuantización INT8 y TensorRT para su despliegue embebido en placas NVIDIA Jetson Orin / Xavier. Esto permitirá integrar la inferencia directamente en la óptica de las cámaras cenitales de la línea.
2. **Refinamiento y curación manual de anotaciones:** Sustituir gradualmente las cajas generadas por algoritmos heurísticos de OpenCV por anotaciones 100 % validadas por inspectores de calidad humanos, cerrando la brecha de precisión geométrica en fallas lineales (**crack** y **scratch**).
3. **Resiliencia ante ruido térmico y óptico:** Implementar bloques de preprocesamiento adaptativo y algoritmos de reducción de ruido (*denoise*) para mitigar el ruido ISO elevado de los sensores y la distorsión por radiación infrarroja en entornos de laminación en caliente.
4. **Aceleración WebGPU en el frontend:** Incorporar el backend de WebGPU en ONNX Runtime Web para triplicar la tasa de cuadros por segundo en equipos con GPU integradas o discretas sin consumo intensivo de CPU.

7. Conclusiones

Este proyecto valida la viabilidad y efectividad de arquitecturas ligeras de aprendizaje profundo (MobileNetV3-Small y YOLOv8n) para la inspección y aseguramiento de calidad en la industria siderúrgica y metalúrgica en tiempo real.

La arquitectura en cascada de dos etapas demuestra ser una estrategia de ingeniería altamente robusta: el clasificador Gate asegura resiliencia ante entradas fuera de dominio y fondos no pertinentes, mientras que el detector multiclase logra localizar y discriminar defectos con un mAP₅₀ de 0.739 sobre escenarios reales.

La integración fluida del pipeline —desde el entrenamiento acelerado en GPU hasta el despliegue en navegador web a 20–30+ FPS mediante WebAssembly— consolida una solución práctica, escalable, privada y de bajo costo para la modernización de los procesos de control de calidad industrial.

Referencias

- [1] Song, K., & Yan, Y. (2013). *A noise robust method based on completed local binary patterns for hot-rolled steel strip surface defect detection*. Applied Surface Science, 285, 858–864. <https://doi.org/10.1016/j.apsusc.2013.09.002>
- [2] Zhao, X. et al. (2024). *SteelDefectX: A Real-World Benchmark Dataset for Steel Surface Defect Detection*. Hugging Face Datasets. <https://huggingface.co/datasets/Zhaosxian/SteelDefectX>
- [3] Abbas, T. *Synthetic Industrial Metal Surface Defects* (15 000 imágenes, CC BY 4.0). Kaggle Datasets. <https://www.kaggle.com/datasets/tatheerabbas/synthetic-industrial-metal-surface-defects>
- [4] Howard, A. et al. (2019). *Searching for MobileNetV3*. IEEE/CVF International Conference on Computer Vision (ICCV), 1314–1324.
- [5] Jocher, G., Chaurasia, A., & Qiu, J. (2023). *Ultralytics YOLOv8*. <https://github.com/ultralytics/ultralytics>
- [6] He, K., Zhang, X., Ren, S., & Sun, J. (2016). *Deep Residual Learning for Image Recognition*. IEEE Conference on Computer Vision and Pattern Recognition (CVPR), 770–778.
- [7] Tan, M., & Le, Q. (2019). *EfficientNet: Rethinking Model Scaling for Convolutional Neural Networks*. International Conference on Machine Learning (ICML), 6105–6114.
- [8] Microsoft (2024). *ONNX Runtime Web: High performance machine learning inference in the browser*. <https://onnxruntime.ai/>
- [9] Gebru, T. et al. (2018). *Datasheets for Datasets*. arXiv:1803.09010.